

Trabalho Clusterização

Análise de Churn com K-Means e Hierárquico

Mateus Ribeiro Gomes

1st July 2026


Contexto do Problema

- **Objetivo:** Agrupar clientes com base em seu perfil de uso para identificar padrões de *churn* (evasão).
- **Dataset:** 3150 amostras, 13 atributos e 1 de label (Churn).
- Todos os atributos, exceto o atributo de churn, representam dados agregados dos primeiros 9 meses. Os rótulos de churn refletem a situação dos clientes ao final de 12 meses.

Atributos:

- | | |
|--------------------------------------|--|
| • Call Failure (número de falhas) | • Age Group(ordinal [1, 5]) |
| • Complains (binário) | • Charge Amount (ordinal [0, 9]) |
| • Subscription Lenght (meses) | • Tariff Plan (binario: pré ou pós pago) |
| • Seconds of Use | • Status (binário: ativo ou não) |
| • Frequency of Use (número de calls) | • Customer Value |
| • Frequency of SMS (número de sms's) | • Churn (binário) |
| • Distinct Called Numbers | |

Pairplot dos Dados



Padronização das Features

- É necessário padronizar as features pois há atributos que possuem grande diferença na ordem de grandeza.
- Exemplo: Seconds of Use está na casa dos milhares, enquanto Call Failure está na casa das dezenas.

$$X_{\text{scaled}} = \frac{X - \mu}{\sigma}$$

Explicação

Sem essa padronização, os algoritmos seriam "ingênuos", ou seja, eles tratariam uma diferença de 1000 segundos de uso como 1000 vezes mais importante do que uma diferença de 1 falha de chamada, simplesmente por causa do valor numérico, e não da relevância estatística.

Algoritmo K-Means

O algoritmo segue o seguinte fluxo:

- 1 Os centroides são inicializados de maneira aleatória.
- 2 Calcula-se a distância de cada ponto para todos os centroides; cada ponto é atribuído ao que apresentar a menor distância.
- 3 Calcula-se a média espacial dos pontos atribuídos a cada centroide.
- 4 O novo centroide passa a ser esse valor da média calculada.
- 5 Repete-se o processo até convergência (centroides param apresentar mudança considerável) ou até o limite máximo de iterações.

Métricas de Distância

Três métricas de distância foram testadas:

Distância Euclidiana

$$d(x, y) = \sqrt{\sum_i (x_i - y_i)^2}$$

Distância de Mahalanobis

$$d(x, y) = \sqrt{(x - y)^T \Sigma^{-1} (x - y)}$$


Distância de Manhattan

$$d(x, y) = \sum_i |x_i - y_i|$$

- Para visualizar os clusters em 2 dimensões, utilizou-se Análise de Componentes Principais (PCA).
- O PCA foi aplicado apenas para visualização, os modelos foram treinados com a dimensão original (13 atributos).
- A PC1 e a PC2 apresentaram $\approx 50\%$ da variância dos dados.


Cotovelo - Distância Euclidiana

- A curva de inércia apresenta uma inflexão clara em $k = 2$.
- A redução da inércia após $k = 2$ torna-se gradual.




Cotovelo - Distância de Mahalanobis

- Comportamento linear, sem pontos de inflexão acentuados.
- Ausência de um “cotovelo” definido indica que o modelo não encontra uma estrutura de separação otimizada.
- A métrica se apresenta como ineficaz para esta base de dados.




Cotovelo - Distância de Manhattan

- Comportamento semelhante ao Euclidiano, com inflexão marcante em $k = 2$.
- A partir de $k = 2$, a inclinação diminui significativamente.




K-Means - Euclidiana $k = 2$

- A distância Euclidiana apresentou bom desempenho na separação dos clusters.




K-Means - Euclidiana $k = 3$




K-Means - Mahalanobis $k = 2$

- Separação fraca entre os clusters.




K-Means - Manhattan $k = 2$

- A distância de Manhattan também apresentou boa separação.



K-Means - Manhattan $k = 3$

- Curiosamente, quando utilizada com $K = 3$, a métrica de manhatam demonstrou uma capacidade razoável de clustrização do espaço.




Impacto de Diferentes Inicializações

- O K-Means é sensível à inicialização dos centroides, podendo convergir para mínimos locais.
- Testamos múltiplas inicializações (sem seed) para 2 cenários gerados:
 - Euclidiana $k = 2$ (melhor desempenho visual)
 - Manhattan $k = 3$ (comportamento curioso)


Euclidiana $k = 2$ - Diferentes Inicializações dos Centroides

Diferentes inicializações dos centroides
Distância: euclidian
 $K = 2$



Manhattan $k = 3$ - Diferentes Inicializações dos Centroides

Diferentes inicializações dos centroides
Distância: manhatam
 $K = 3$



Probabilidade de Churn por Cluster

Métrica	Cluster	Prob. Churn
Euclidiana $k = 2$	0	0.75%
	1	25.03%
Mahalanobis $k = 2$	0	15.30%
	1	19.27%
Manhattan $k = 2$	0	0.33%
	1	22.09%
Manhattan $k = 3$	0	26.18%
	1	1.58%
	2	0.49%

Conclusões - KMeans

Euclidiana

Bom desempenho: Cluster 0 com 0.75% e Cluster 1 com 25.03% de Churn.
Adequação da métrica à geometria dos dados.

Mahalanobis

Desempenho limitado (15.30% vs 19.27%).
A premissa de normalidade multivariada não é atendida pelos dados (distribuições não normais e assimétricas).

Manhattan

Boa abordagem: com $k = 2$ (0.33% vs 22.09%).
Com $k = 3$, revela uma possível terceira categoria de risco moderado, isolando melhor o segmento de alta evasão.

Algoritmo Hierárquico Aglomerativo (Bottom-Up)

- 1 Inicia-se com pontos individuais (cada ponto é seu próprio cluster).
- 2 Calcula-se a distância entre todos os pares de clusters.
- 3 Identificam-se os dois clusters mais próximos e unem-os.
- 4 Recalculam-se as distâncias entre o novo cluster e os demais.
- 5 Repete-se até que todos os pontos estejam em um único cluster.

Métodos de Linkage

Assuma um cluster u resultante da junção de dois outros clusters s e t , e v qualquer outro cluster diferente:

- **Single:**

$$d(u, v) = \min(\text{dist}(u[i], v[j]))$$

- **Complete:**

$$d(u, v) = \max(\text{dist}(u[i], v[j]))$$

- **Average:**

$$d(u, v) = \sum_{ij} \frac{\text{dist}(u[i], v[j])}{|u| \cdot |v|}$$

- **Ward:**

$$d(u, v) = \sqrt{\frac{|v| + |s|}{T} d(v, s)^2 + \frac{|v| + |t|}{T} d(v, t)^2 - \frac{|v|}{T} d(s, t)^2}$$

onde $T = |v| + |s| + |t|$ e $|*|$ é o operador de cardinalidade.

Dendrogramas - 4 Métodos de Linkage




Figure: Dendrogramas para os métodos Single, Complete, Average e Ward.

Análise dos métodos

Single

- Apresenta um forte efeito de "escada", unindo os dados de forma sequencial.
- É a topologia que se demonstrou menos adequada para a clusterização de perfis nesta base de dados.

Complete

- Gera uma árvore com muitas sub-ramificações que demoram mais para se juntarem.
- Pode dividir grupos que naturalmente pertenceriam juntos devido à sensibilidade às extremidades dos clusters.

Average

- Atua como um meio-termo matemático entre os extremos dos métodos Single e Complete.
- Agrupa os clientes calculando a distância média entre todos os pares.
- Constrói uma topologia útil, mas ainda preserva galhos irregulares na base da árvore.

Ward

- Agrupa os clientes minimizando a variância interna, gerando os clusters mais homogêneos possíveis.
- Produz ramificações espessas e simétricas, facilitando a identificação visual do ponto de corte ideal (k).
- É o método que se demonstrou mais adequado ao conjunto para isolar as fronteiras do risco de churn.

Clusters Hierárquicos com PCA

Comparação dos Métodos Hierárquicos - Plot com PCA em 2D

$K=2$




Figure: Visualização dos clusters hierárquicos projetados em 2D com PCA.

Probabilidade de Churn por Método de Linkage

Método	Cluster	Prob. Churn
Single	0	15.69%
	1	100.00%
Complete	0	0.00%
	1	16.53%
Average	0	0.00%
	1	16.20%
Ward	0	24.56%
	1	0.52%

- **Single:** Cluster 1 com 100% de Churn, mas apenas 1 cliente, efeito de *chaining*.
- **Complete:** Cluster 0 com 0% de Churn e Cluster 1 com 16.53%, boa separação.
- **Average:** Resultado similar ao Complete (0% e 16.20%).
- **Ward:** Cluster 0 com 24.56% e Cluster 1 com 0.52%, boa separação também.
- Ward e Complete apresentam a melhor separação de risco de Churn.

Conclusão Final Sobre os Métodos

- **K-Means com distância Euclidiana ($k = 2$) e Manhattan ($k = 2$)** são as abordagens mais eficazes para segmentar clientes por risco de Churn.
- **Mahalanobis** mostrou-se inadequada para este conjunto de dados devido à não normalidade.
- **Hierárquico com Ward** também apresenta boa separação espacial.


Table: Perfil Médio de Consumo por Cluster (K-Médias Euclidiana, $k = 2$)

Variável	Cluster 0	Cluster 1
Call Failure	11.63	5.14
Complains	0.02	0.11
Subscription Length	33.96	31.66
Charge Amount	1.89	0.35
Seconds of Use	8167.33	2174.11
Frequency of use	119.25	38.49
Frequency of SMS	146.46	27.59
Distinct Called Numbers	35.91	15.80
Age Group	2.89	2.79
Tariff Plan	1.18	1.02
Status	1.00	1.40
Age	31.59	30.63
Customer Value	908.68	198.70
Churn	0.0075	0.25

- Podemos ver que os clientes que possuem alto consumo estão classificados no cluster 0, o qual apresenta apenas 0.75% de churn.
- O cluster 0 apresenta um perfil empresarial, dado a grande quantidade de números distintos apresentada, além de apresentar um valor baixo de churn mesmo com uma quantidade razoável de falhas, também mostra um grande valor agregado de cliente.
- O cluster 1 apresenta um perfil de usuários móvel, dado um menor valor agregado de cliente, uma taxa maior de reclamações, uma frequência de uso bem menor e um plano de tarifa mais próximo do pré pago.

Analisando com dados não padronizados

Comparação KMeans com distância euclidiana com $K = 2$



- A variável *Seconds of Use* (na casa dos milhares) passa a monopolizar o cálculo da distância, anulando o peso das demais métricas.
- Sem a padronização, o modelo ignora atributos de menor escala, porém essenciais para prever o risco (como *Complains* e *Call Failure*).
- Ou seja, o algoritmo atuou mais como um "Separador de Tempo de Uso"

Obrigado pela atenção!

Dúvidas?