

# Trabalho Clusterização

## Análise de Churn com K-Means e Hierárquico

Mateus Ribeiro Gomes

12th July 2026


# Contexto do Problema

- **Objetivo:** Agrupar clientes com base em seu perfil de uso para identificar padrões de *churn* (evasão).
- **Dataset:** 3150 amostras, 13 atributos e 1 de label (Churn).
- Todos os atributos, exceto o atributo de churn, representam dados agregados dos primeiros 9 meses. Os rótulos de churn refletem a situação dos clientes ao final de 12 meses.

## Atributos:

- |                                      |                                          |
|--------------------------------------|------------------------------------------|
| • Call Failure (número de falhas)    | • Age Group(ordinal [1, 5])              |
| • Complains (binário)                | • Charge Amount (ordinal [0, 9])         |
| • Subscription Lenght (meses)        | • Tariff Plan (binario: pré ou pós pago) |
| • Seconds of Use                     | • Status (binário: ativo ou não)         |
| • Frequency of Use (número de calls) | • Customer Value                         |
| • Frequency of SMS (número de sms's) | • Churn (binário)                        |
| • Distinct Called Numbers            |                                          |

# Pairplot dos Dados



# Padronização das Features

- É necessário padronizar as features pois há atributos que possuem grande diferença na ordem de grandeza.
- Exemplo: Seconds of Use está na casa dos milhares, enquanto Call Failure está na casa das dezenas.

$$X_{\text{scaled}} = \frac{X - \mu}{\sigma}$$

## Explicação

Sem essa padronização, os algoritmos seriam "ingênuos", ou seja, eles tratariam uma diferença de 1000 segundos de uso como 1000 vezes mais importante do que uma diferença de 1 falha de chamada, simplesmente por causa do valor numérico, e não da relevância estatística.

O algoritmo segue o seguinte fluxo:

- 1 Os centroides são inicializados de maneira aleatória.
- 2 Calcula-se a distância de cada ponto para todos os centroides; cada ponto é atribuído ao que apresentar a menor distância.
- 3 Calcula-se a média espacial dos pontos atribuídos a cada centroide.
- 4 O novo centroide passa a ser esse valor da média calculada.
- 5 Repete-se o processo até convergência (centroides param apresentar mudança considerável) ou até o limite máximo de iterações.

# Métricas de Distância

Três métricas de distância foram testadas:

## Distância Euclidiana

$$d(x, y) = \sqrt{\sum_i (x_i - y_i)^2}$$

## Distância de Mahalanobis

$$d(x, y) = \sqrt{(x - y)^T \Sigma^{-1} (x - y)}$$


## Distância de Manhattan

$$d(x, y) = \sum_i |x_i - y_i|$$

- Para visualizar os clusters em 2 dimensões, utilizou-se Análise de Componentes Principais (PCA).
- O PCA foi aplicado apenas para visualização, os modelos foram treinados com a dimensão original (13 atributos).
- A PC1 e a PC2 apresentaram  $\approx 50\%$  da variância dos dados.


# Cotovelo - Distância Euclidiana

- A curva de inércia apresenta uma inflexão clara em  $k = 2$ .
- A redução da inércia após  $k = 2$  torna-se gradual.




# Cotovelo - Distância de Mahalanobis

- Comportamento linear, sem pontos de inflexão acentuados.
- Ausência de um “cotovelo” definido indica que o modelo não encontra uma estrutura de separação otimizada.
- A métrica se apresenta como ineficaz para esta base de dados.




# Cotovelo - Distância de Manhattan

- Comportamento semelhante ao Euclidiano, com inflexão marcante em  $k = 2$ .
- A partir de  $k = 2$ , a inclinação diminui significativamente.




# K-Means - Euclidiana $k = 2$

- A distância Euclidiana apresentou bom desempenho na separação dos clusters.




# K-Means - Euclidiana $k = 3$




# K-Means - Mahalanobis $k = 2$

- Separação fraca entre os clusters.




# K-Means - Manhattan $k = 2$

- A distância de Manhattan também apresentou boa separação.



# K-Means - Manhattan $k = 3$


- Curiosamente, quando utilizada com  $K = 3$ , a métrica de manhatam demonstrou uma capacidade razoável de clustrização do espaço.



- O K-Means é sensível à inicialização dos centroides, podendo convergir para mínimos locais.
- Testamos múltiplas inicializações (sem seed) para 2 cenários gerados:
  - Euclidiana  $k = 2$  (melhor desempenho visual)
  - Manhattan  $k = 3$  (comportamento curioso)


# Euclidiana $k = 2$ - Diferentes Inicializações dos Centroides

Diferentes inicializações dos centroides  
Distância: euclidian  
 $K = 2$



# Manhattan $k = 3$ - Diferentes Inicializações dos Centroides

Diferentes inicializações dos centroides  
Distância: manhatam  
 $K = 3$



# Probabilidade de Churn por Cluster

| Métrica             | Cluster | Prob. Churn |
|---------------------|---------|-------------|
| Euclidiana $k = 2$  | 0       | 0.75%       |
|                     | 1       | 25.03%      |
| Mahalanobis $k = 2$ | 0       | 15.30%      |
|                     | 1       | 19.27%      |
| Manhattan $k = 2$   | 0       | 0.33%       |
|                     | 1       | 22.09%      |
| Manhattan $k = 3$   | 0       | 26.18%      |
|                     | 1       | 1.58%       |
|                     | 2       | 0.49%       |

# Conclusões - KMeans

## Euclidiana

Bom desempenho: Cluster 0 com 0.75% e Cluster 1 com 25.03% de Churn.  
Adequação da métrica à geometria dos dados.

## Mahalanobis

Desempenho limitado (15.30% vs 19.27%).  
A premissa de normalidade multivariada não é atendida pelos dados (distribuições não normais e assimétricas).

## Manhattan

Boa abordagem: com  $k = 2$  (0.33% vs 22.09%).  
Com  $k = 3$ , revela uma possível terceira categoria de risco moderado, isolando melhor o segmento de alta evasão.

# Algoritmo Hierárquico Aglomerativo (Bottom-Up)

- 1 Inicia-se com pontos individuais (cada ponto é seu próprio cluster).
- 2 Calcula-se a distância entre todos os pares de clusters.
- 3 Identificam-se os dois clusters mais próximos e unem-os.
- 4 Recalculam-se as distâncias entre o novo cluster e os demais.
- 5 Repete-se até que todos os pontos estejam em um único cluster.

# Métodos de Linkage

Assuma um cluster  $u$  resultante da junção de dois outros clusters  $s$  e  $t$ , e  $v$  qualquer outro cluster diferente:

- **Single:**

$$d(u, v) = \min(\text{dist}(u[i], v[j]))$$

- **Complete:**

$$d(u, v) = \max(\text{dist}(u[i], v[j]))$$

- **Average:**


$$d(u, v) = \sum_{ij} \frac{\text{dist}(u[i], v[j])}{|u| \cdot |v|}$$

- **Ward:**

$$d(u, v) = \sqrt{\frac{|v| + |s|}{T} d(v, s)^2 + \frac{|v| + |t|}{T} d(v, t)^2 - \frac{|v|}{T} d(s, t)^2}$$

onde  $T = |v| + |s| + |t|$  e  $|*|$  é o operador de cardinalidade.

# Dendrogramas - 4 Métodos de Linkage



**Figure:** Dendrogramas para os métodos Single, Complete, Average e Ward.

# Análise dos métodos

## Single

- Apresenta um forte efeito de "escada", unindo os dados de forma sequencial.
- É a topologia que se demonstrou menos adequada para a clusterização de perfis nesta base de dados.

## Complete

- Gera uma árvore com muitas sub-ramificações que demoram mais para se juntarem.
- Pode dividir grupos que naturalmente pertenceriam juntos devido à sensibilidade às extremidades dos clusters.

## Average

- Atua como um meio-termo matemático entre os extremos dos métodos Single e Complete.
- Agrupa os clientes calculando a distância média entre todos os pares.
- Constrói uma topologia útil, mas ainda preserva galhos irregulares na base da árvore.

## Ward

- Agrupa os clientes minimizando a variância interna, gerando os clusters mais homogêneos possíveis.
- Produz ramificações espessas e simétricas, facilitando a identificação visual do ponto de corte ideal ( $k$ ).
- É o método que se demonstrou mais adequado ao conjunto para isolar as fronteiras do risco de churn.

# Clusters Hierárquicos com PCA

Comparação dos Métodos Hierárquicos - Plot com PCA em 2D

$K=2$




Figure: Visualização dos clusters hierárquicos projetados em 2D com PCA.

# Probabilidade de Churn por Método de Linkage

| Método   | Cluster | Prob. Churn |
|----------|---------|-------------|
| Single   | 0       | 15.69%      |
|          | 1       | 100.00%     |
| Complete | 0       | 0.00%       |
|          | 1       | 16.53%      |
| Average  | 0       | 0.00%       |
|          | 1       | 16.20%      |
| Ward     | 0       | 24.56%      |
|          | 1       | 0.52%       |

- **Single:** Cluster 1 com 100% de Churn, mas apenas 1 cliente, efeito de *chaining*.
- **Complete:** Cluster 0 com 0% de Churn e Cluster 1 com 16.53%, boa separação.
- **Average:** Resultado similar ao Complete (0% e 16.20%).
- **Ward:** Cluster 0 com 24.56% e Cluster 1 com 0.52%, boa separação também.
- Ward e Complete apresentam a melhor separação de risco de Churn.

# Conclusão Final Sobre os Métodos

- **K-Means com distância Euclidiana ( $k = 2$ ) e Manhattan ( $k = 2$ )** são as abordagens mais eficazes para segmentar clientes por risco de Churn.
- **Mahalanobis** mostrou-se inadequada para este conjunto de dados devido à não normalidade.
- **Hierárquico com Ward** também apresenta boa separação espacial.


**Table:** Perfil Médio de Consumo por Cluster (K-Médias Euclidiana,  $k = 2$ )

| Variável                | Cluster 0 | Cluster 1 |
|-------------------------|-----------|-----------|
| Call Failure            | 11.63     | 5.14      |
| Complains               | 0.02      | 0.11      |
| Subscription Length     | 33.96     | 31.66     |
| Charge Amount           | 1.89      | 0.35      |
| Seconds of Use          | 8167.33   | 2174.11   |
| Frequency of use        | 119.25    | 38.49     |
| Frequency of SMS        | 146.46    | 27.59     |
| Distinct Called Numbers | 35.91     | 15.80     |
| Age Group               | 2.89      | 2.79      |
| Tariff Plan             | 1.18      | 1.02      |
| Status                  | 1.00      | 1.40      |
| Age                     | 31.59     | 30.63     |
| Customer Value          | 908.68    | 198.70    |
| Churn                   | 0.0075    | 0.25      |

- Podemos ver que os clientes que possuem alto consumo estão classificados no cluster 0, o qual apresenta apenas 0.75% de churn.
- O cluster 0 apresenta um perfil empresarial, dado a grande quantidade de números distintos apresentada, além de apresentar um valor baixo de churn mesmo com uma quantidade razoável de falhas, também mostra um grande valor agregado de cliente.
- O cluster 1 apresenta um perfil de usuários móvel, dado um menor valor agregado de cliente, uma taxa maior de reclamações, uma frequência de uso bem menor e um plano de tarifa mais próximo do pré pago.

# Analisando com dados não padronizados

Comparação KMeans com distância euclidiana com  $K = 2$



- A variável *Seconds of Use* (na casa dos milhares) passa a monopolizar o cálculo da distância, anulando o peso das demais métricas.
- Sem a padronização, o modelo ignora atributos de menor escala, porém essenciais para prever o risco (como *Complains* e *Call Failure*).
- Ou seja, o algoritmo atuou mais como um "Separador de Tempo de Uso"

# Obrigado pela atenção!

Dúvidas?