

Processos Estocásticos II

Prof. Charles Casimiro Cavalcante

`charles@ufc.br`

Departamento de Engenharia de Teleinformática

Universidade Federal do Ceará – UFC

<http://charlescasimiro.github.io/>



UNIVERSIDADE
FEDERAL DO CEARÁ


“Tudo que existe no universo é fruto do acaso.”

Demócrito (pensador grego, 460 a.C.-370 a.C.)


- ❶ Cadeias de Markov
- ❷ Análise Espectral de Processos Estocásticos
- ❸ Modelos probabilísticos para aprendizado de máquinas

Cadeias de Markov

Rede celular: número de usuários ativos em dado momento.





Hora 9:00



Hora 14:00

Rede celular: número de usuários ativos em dado momento.



Definição

Um processo estocástico (aleatório) $X(t)$ é um *processo de Markov* se o futuro do processo **dado** o presente é independente do passado. Pode ser visto como uma generalização dos experimentos *independentes*.

? Mas o que significa isso?

Qual a relação estatística que podemos extrair desta definição?

Para tempos arbitrários $t_0 < t_1 < \dots < t_k < t_{k+1}$

Processo discreto

$$\begin{aligned}\Pr[X(t_{k+1}) = x_{k+1} | X(t_k) = x_k, \dots, X(t_0) = x_0] \\ = \Pr[X(t_{k+1}) = x_{k+1} | X(t_k) = x_k],\end{aligned}\tag{1}$$

Processo contínuo

$$\begin{aligned}\Pr[a < X(t_{k+1}) \leq b | X(t_k) = x_k, \dots, X(t_0) = x_0] \\ = \Pr[a < X(t_{k+1}) \leq b | X(t_k) = x_k],\end{aligned}\tag{2}$$

Os processos de Markov podem ser classificados não só pelo seu parâmetro, contínuo ou discreto, mas também pelo **espaço dos estados** (conjunto dos possíveis valores do processo estocástico), que também pode ser contínuo ou discreto. Os processos de Markov cujo espaço de estados é discreto, dizem-se **Cadeias de Markov**.

O caso que nos vai interessar será o das **Cadeias de Markov de parâmetro discreto**.

As Equações (1) e (2) caracterizam a **propriedade markoviana**.

Assim, podemos definir uma **cadeia de Markov** como sendo um processo estocástico que satisfaz as seguintes condições:

- ❶ o parâmetro k é discreto
- ❷ o espaço de estados E é discreto (finito ou infinito enumerável)
- ❸ o estado inicial do processo ou do espaço de estados é conhecido
- ❹ vale a **propriedade markoviana**
- ❺ vale a *propriedade da estacionariedade*

A propriedade markoviana nos diz que as probabilidades (cumulativas e densidades também) de todos os estados futuros X_j ($j > k$) dependem somente do estado atual X_k , ou seja, não dependem dos estados anteriores $X_0, X_1, \dots, X_{k-1}$.

O estado “futuro” do sistema depende do “presente” mas não do “passado”.

Relembrando a propriedade markoviana (caso discreto), temos

$$\begin{aligned}\Pr[X(t_{k+1}) = x_{k+1} | X(t_k) = x_k, \dots, X(t_0) = x_0] \\ = \Pr[X(t_{k+1}) = x_{k+1} | X(t_k) = x_k],\end{aligned}\tag{3}$$

Vamos então denotar os valores para o processo estocástico nos instantes determinados como **estados**.

Assim, vamos associar os valores $x_0, x_1, \dots, x_k$ a um conjunto de estados denotados por $s_0, s_1, \dots, s_k$.

Assim, de forma geral, a função da probabilidade de transição pode ser escrita como:

Função de probabilidade de transição

$$p_{ij}(m, n) = \Pr(X_n = s_j | X_m = s_i) \quad (4)$$

ou seja, a probabilidade do sistema estar no estado s_j no momento n dado que no momento m esteve no estado s_i .

Caso de interesse: Cadeia de Markov homogênea

- Cadeia de Markov é dita ser homogênea ou estacionária se $p_{ij}(m, n)$ depende apenas da diferença $n - m$.
- Chamamos então função de **probabilidade de transição em n passos** da Cadeia de Markov homogênea a função

$$\begin{aligned} p_{ij}(n) &= \Pr(X_{n+t} = s_j | X_t = s_i) \\ &= \Pr(X_n = s_j | X_0 = s_i), \quad \forall t \geq 0, t \in \mathbb{N}. \end{aligned} \tag{5}$$

Uma transição de transição particularmente importante em uma cadeia de Markov homogênea é a **transição de um passo**, dada por

Probabilidade de transição de um passo

$$\begin{aligned} p_{ij}(1) &= \Pr(X_{n+1} = s_j | X_n = s_i) \\ &= \Pr(X_1 = s_j | X_0 = s_i), \quad \forall t \geq 0, t \in \mathbb{N}. \end{aligned} \tag{6}$$

Nota-se que as Equações (5) e (6) dependem apenas de duas informações: do estado inicial (i) e estado final (j).



Assim, uma representação natural para tais probabilidades de forma mais compacta é também uma representação de apenas duas coordenadas, o que nos leva a uma **representação matricial**.

Isso nos leva à definição das matrizes de probabilidade de transição, na sequência.

Matrizes de probabilidade de transição

$$\mathbf{P}(n) = [p_{ij}(n)] \quad (7)$$

para transição de n passos, e

$$\mathbf{P}(1) = [p_{ij}(1)] \quad (8)$$

para transição de um passo. Usualmente, a matriz de transição de um passo é também denotada apenas como $\mathbf{P}$.

As matrizes de probabilidade de transição **não** são matrizes quaisquer e possuem algumas condições:

 **Elementos são probabilidades**

$$p_{ij}(n) \geq 0, \quad \forall i, j \quad (9)$$

 **Soma dos eventos possíveis**

$$\sum_j p_{ij}(n) = 1, \quad \forall i, j \quad (10)$$

Matriz de probabilidade de transição - cont.

A matriz de transição (de um passo) tem então a seguinte estrutura geral:

$$\mathbf{P} = \begin{matrix} & \begin{matrix} s_1 & s_2 & \cdots & s_M \end{matrix} \\ \begin{matrix} s_1 \\ s_2 \\ \vdots \\ s_M \end{matrix} & \begin{pmatrix} p_{11} & p_{12} & \cdots & p_{1M} \\ p_{21} & p_{22} & \cdots & p_{2M} \\ \vdots & \vdots & \ddots & \vdots \\ p_{M1} & p_{M2} & \cdots & p_{MM} \end{pmatrix} \end{matrix} \quad (11)$$

Escolha: linhas/colunas correspondem ao estado inicial/final. Ao longo dos slides iremos usar as linhas como o **estado de origem** e as colunas como **estados destino**.

? Mas o que a matriz de transição revela?

São as possibilidades do sistema (cadeia de Markov) *transitar* entre diferentes estados. E isso é muito útil para entendermos e calcularmos quais são os estados mais prováveis e possíveis.

Outras probabilidades em cadeias de Markov

- ➡ Outras probabilidades importantes em cadeias de Markov
- ➡ Probabilidade (não condicional) de no instante n o sistema estar no estado s_j , ou seja


$$p_j(n) = \Pr(X_n = s_j) \quad (12)$$

- ➡ Vetor de probabilidades: agrupa as probabilidades para os diversos estados de uma cadeia de Markov, em um dado instante n ,

$$\mathbf{p}(n) = \begin{bmatrix} p_0(n) & p_1(n) & \cdots & p_M(n) \end{bmatrix} \quad (13)$$

Diagramas de cadeias de Markov

- ➡ Uma ferramenta útil em cadeias de Markov discretas e homogêneas (ou estacionárias) é a ilustração da mesma como um **grafo orientado**.
- ➡ Lembrando: nas cadeias de Markov estacionárias as probabilidades de transição são constantes.
- ➡ Com isso, temos a seguinte possibilidade de representação



Exemplo

Suponha que em *Nárnia* (ou *Terra Média*), nunca há dois dias ensolarados consecutivos.


- ▶ Se em um dia qualquer faz sol, no dia seguinte pode tanto nevar quanto chover.
- ▶ Se chover, metade das vezes continua chovendo no dia seguinte e nas outras ocasiões pode tanto fazer sol ou nevar.
- ▶ Se nevar, apenas metade das vezes o dia seguinte também neva.

Queremos:

- (a) Representar graficamente a Cadeia de Markov;
- (b) Construir sua matriz de probabilidades de transição;
- (c) Determinar a probabilidade de nevar daqui a dois dias?

Diagramas de cadeias de Markov - cont.

Exemplo - cont.



$$\mathbf{P} = \begin{pmatrix} 0 & p_1 & q_1 \\ p_2 & 1/2 & q_2 \\ p_3 & q_3 & 1/2 \end{pmatrix}$$

? Mas.... e qual a probabilidade de nevar daqui a dois dias?

Como descrito, elemento $p_{ij}(n)$ da matriz $P(n)$ representa a probabilidade de que o processo, iniciado no estado s_i , estará no estado s_j , depois de n passos.

Uma questão importante então é a consideração de sair, por exemplo, do estado s_i no instante $t = 0$, passando pelo estado s_k no instante $t = m$ e atingindo o estado s_j no instante $t = n + m$.



A resposta a esta questão leva às **equações de Chapman-Kolmogorov**.

Calculando a probabilidade de transição de n -passos...

Sabemos que a propriedade markoviana diz que:

$$\begin{aligned}\Pr[X(t_{k+1}) = s_{k+1} | X(t_k) = s_k, \dots, X(t_1) = s_1] &= \\ &= \Pr[X(t_{k+1}) = s_{k+1} | X(t_k) = s_k]\end{aligned}\tag{14}$$

Da definição de probabilidade condicional que, para três eventos, temos:

$$\begin{aligned}\Pr[X(t_3) = s_3 | X(t_2) = s_2, X(t_1) = s_1] &= \\ &= \frac{\Pr[X(t_3) = s_3, X(t_2) = s_2, X(t_1) = s_1]}{\Pr[X(t_2) = s_2, X(t_1) = s_1]}\end{aligned}\tag{15}$$

Podemos ainda escrever, para dois eventos, que

$$\Pr[X(t_2) = s_2 | X(t_1) = s_1] = \frac{\Pr[X(t_2) = s_2, X(t_1) = s_1]}{\Pr[X(t_1) = s_1]} \quad (16)$$

Estamos interessados em calcular a probabilidade de transição entre os estados i e j de uma Cadeia de Markov em n passos, ou seja, calcular:

$$p_{ij}(n) = \Pr[X_{n+k} = s_j | X_k = s_i] = \Pr[X_n = s_j | X_0 = s_i]. \quad (17)$$

Vamos iniciar com dois passos. Temos então o seguinte:

$$\begin{aligned} p_{ij}(2) &= \Pr[X_2 = s_j, X_1 = s_k, X_0 = s_i] \\ &= \frac{\Pr[X_2 = s_j, X_1 = s_k | X_0 = s_i]}{\Pr[X_0 = s_i]} \end{aligned} \quad (18)$$

E utilizando (15) na expressão em (18) temos que:

$$\begin{aligned} p_{ij}(2) &= \frac{\Pr[X_2 = s_j | X_1 = s_k] \cdot \Pr[X_1 = s_k | X_0 = s_i] \cdot \Pr[X_0 = s_i]}{\Pr[X_0 = s_i]} \\ &= \Pr[X_2 = s_j | X_1 = s_k] \cdot \Pr[X_1 = s_k | X_0 = s_i] \\ &= p_{kj}(1) \cdot p_{ik}(1) \end{aligned} \quad (19)$$

Equações de Chapman-Kolmogorov - cont.

Para todas as variações dos possíveis k estados que podem servir de caminho parcial entre i e j teremos a soma das probabilidades de tais caminhos, assim:

$$p_{ij}(2) = \sum_k p_{ik}(1) \cdot p_{kj}(1) \quad (20)$$

E generalizando para um número de passos $m + n$, feito através do uso de um maior número de expressões de eventos condicionados e do uso da propriedade markoviana dada em (14), temos o seguinte resultado:

$$p_{ij}(m + n) = \sum_k p_{ik}(m) \cdot p_{kj}(n) \quad (21)$$

Equações de Chapman-Kolmogorov - cont.



A Equação (21) (descrita novamente abaixo) é chamada de equação de **Chapman-Kolmogorov** e é um importante resultado de probabilidade para o estudo de Cadeias de Markov e cálculo de probabilidades de transição.

$$p_{ij}(m+n) = \sum_k p_{ik}(m) \cdot p_{kj}(n)$$



No caso de termos uma cadeia de Markov estacionária temos que as probabilidades de transição entre quaisquer dois estados, para dois instantes consecutivos, são constantes.

Equações de Chapman-Kolmogorov - cont.

De acordo com a Equação (21) podemos escrever então a seguinte relação para a matriz de probabilidade de transição:

$$\mathbf{P}(n + m) = \{p_{ij}(n + m)\} \quad (22)$$

Assim, a matriz de probabilidade de transição para n passos, representada por $\mathbf{P}(n)$, tem a seguinte propriedade:

$$\begin{aligned} \mathbf{P}(n + m) &= \mathbf{P}(n) \cdot \mathbf{P}(m) \\ \mathbf{P}(n) &= \mathbf{P}^n = \prod_{i=1}^n \mathbf{P} \end{aligned} \quad (23)$$

Vetor de probabilidades iniciais

Em muitas situações se desconhece o estado da cadeia de Markov no instante inicial.

Para $i = 1, 2, \dots, M$, consideramos p_i como a probabilidade de que o processo esteja no estado s_i no instante inicial.

Nestes casos, se associa probabilidades também para os estados da cadeia, no instante inicial. Assim, define-se o **vetor de probabilidades iniciais** $\mathbf{p}(0) = [p_1(0) \ \cdots \ p_M(0)]$, cujos elementos do vetor são definidos segundo:

$$\begin{aligned} p_i(0) &\geq 0 \\ \sum_i^M p_i(0) &= 1 \end{aligned} \tag{24}$$

Agora vamos considerar as probabilidades dos estados em um instante de tempo n . Seja $\mathbf{p}(n)$ o vetor de probabilidades no instante n .

A probabilidade $p_j(n)$ é relacionada ao vetor $\mathbf{p}(n-1)$ pela seguinte equação:

$$\begin{aligned} p_j(n) &= \sum_i \Pr[X_n = s_j | X_{n-1} = s_i] \cdot \Pr[X_{n-1} = s_i] \\ &= \sum_i p_{ij} \cdot p_i(n-1) \end{aligned} \tag{25}$$



A Equação (25) diz que o vetor de estados no instante n $\mathbf{p}(n)$ é obtido multiplicando o vetor $\mathbf{p}(n - 1)$ pela matriz $\mathbf{P}$, ou seja:

$$\mathbf{p}(n) = \mathbf{p}(n - 1) \cdot \mathbf{P} \quad (26)$$

De forma similar, podemos escrever a dependência de $p_j(n)$ com o vetor de estados iniciais $\mathbf{p}(0)$ como

$$\begin{aligned} p_j(n) &= \sum_i \Pr[X_n = s_j | X_0 = s_i] \cdot \Pr[X_0 = s_i] \\ &= \sum_i p_{ij}(n) p_i(0) \end{aligned} \tag{27}$$



E em notação matricial temos

$$\mathbf{p}(n) = \mathbf{p}(0)\mathbf{P}(n) = \mathbf{p}(0) \cdot \mathbf{P}^n \tag{28}$$

A partir da Equação (28), notamos que o produto da matriz de probabilidades de transição tem um papel essencial na determinação dos estados atingíveis da cadeia de Markov.

? Surge então a questão: os valores de $p(n)$ convergem para algum valor limite quando $n \rightarrow \infty$

A estas probabilidades de *equilíbrio* são chamadas **probabilidades de estado estacionárias**.

Matematicamente, o que temos é que, quando $n \rightarrow \infty$, a matriz de probabilidade de se aproxima de uma matriz na qual as linhas tem a mesma distribuição, ou seja

$$p_{ij}(n) \rightarrow \pi_j, \quad \forall i \quad (29)$$

Para escrever a Equação (29) em notação matricial podemos ter:

$$\mathbf{P}^n \rightarrow \mathbf{1}\pi, \quad (30)$$

em que $\mathbf{1}$ é um vetor coluna com todas as posições igual a 1, ou seja, $\mathbf{1}^T = \begin{bmatrix} 1 & 1 & \dots \end{bmatrix}$ e $\pi = \begin{bmatrix} \pi_0 & \pi_1 & \dots \end{bmatrix}$.

Da Equação (27), a convergência de $\mathbf{P}^n$ implica a convergência dos seguintes estados:

$$p_j(n) = \sum_i p_{ij}(n) \cdot p_i(0) \rightarrow \sum_i \pi_i \cdot p_i(0) = \pi_j \quad (31)$$

Quando a Equação (31) é válida dizemos que o sistema (cadeia de Markov) atinge o “**equilíbrio**” ou “**estado permanente**”.

Podemos encontrar a distribuição de π uma vez que notamos que para $n \rightarrow \infty$, temos $p_j(n) \rightarrow \pi_j$ e também $p_j(n-1) \rightarrow \pi_j$. Com isso, podemos escrever a Equação (25) como

$$\pi_j = \sum_i p_{ij} \pi_i, \quad (32)$$

o que em notação matricial é escrito como

$$\pi = \pi P. \quad (33)$$

Também sabe-se que

$$\sum_i \pi_i = 1, \quad (34)$$

já que os elementos do vetor são probabilidades.

Chamamos o vetor π a **distribuição de probabilidade de estado estacionário** da cadeia de Markov.

Se iniciarmos a cadeia de Markov com o vetor de estados iniciais $\mathbf{p}(0) = \boldsymbol{\pi}$ então, pelas Equações (28) e (33), temos que


$$\mathbf{p}(n) = \boldsymbol{\pi} \mathbf{P}^n = \boldsymbol{\pi} \quad (35)$$

Isso significa que

- ❶ Probabilidades são independentes da escolha do instante inicial, e;
- ❷ O processo é estacionário.

Escolha de páginas visitadas

Um navegador da internet procura páginas em um universo de 5 páginas, conforme a figura abaixo. O navegador seleciona a próxima página a ser vista selecionando com igual probabilidade as páginas apontadas pela página atual. Se uma página não tem link de saída (por exemplo, a página 2), o navegador então seleciona qualquer das páginas do universo com igual probabilidade. **Encontrar a probabilidade do navegador mostrar a página i .**




Exemplo - cont.

Escolha de páginas visitadas - cont.

Podemos modelar o comportamento descrito como uma cadeia de Markov onde o estado representa a página atualmente visualizada. Se a página atual aponta para k páginas, então a próxima página é selecionada daquele grupo com probabilidade $\frac{1}{k}$. Se a página atual não aponta para nenhuma outra, então a próxima página pode ser qualquer uma das 5 páginas com probabilidade $\frac{1}{5}$. A matriz de probabilidades de

transição é escrita então como

$$\mathbf{P} = \begin{bmatrix} 0 & 1/2 & 1/2 & 0 & 0 \\ 1/5 & 1/5 & 1/5 & 1/5 & 1/5 \\ 1/3 & 1/3 & 0 & 1/3 & 0 \\ 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 1/2 & 1/2 & 0 \end{bmatrix}$$



Escolha de páginas visitadas - cont.

Podemos então usar a Eq. (28) para encontrar os estados para cada instante.

Para tentar ver quando o sistema se estabiliza, podemos usar algum software de simulação para calcular $\mathbf{P}^n$ para $n = 50$, por exemplo. Neste caso, estamos avaliando a estabilização do processo e as probabilidades de estado estacionário. Para este caso específico, teríamos então

$$\mathbf{p}(50) = \begin{bmatrix} 0.1229 & 0.18447 & 0.25825 & 0.12298 & 0.31974 \end{bmatrix}$$

Mas podemos usar a Eq. (35) para calcular as probabilidades de estado estacionário exatas.

Escolha de páginas visitadas - cont.

O modelo de visualização aleatória por meio de uma cadeia de Markov forma a base do algoritmo do **PageRank** que foi introduzido pelo Google e que classifica a importância de uma página na Web.

Os estados de uma cadeia de Markov podem ser divididas em uma ou mais classes separadas e estas classes podem ser de vários tipos.

Estado acessível - dizemos que o estado j é acessível a partir do estado i se, para algum $n \geq 0$, $p_{ij}(n) > 0$. Ou seja, que ha uma sequência de transições de i para j que possui probabilidade não-nula.

Estado comunicável - dizemos que os estados i e j são comunicáveis se eles são acessíveis de um para o outro. Escreve-se então $i \leftrightarrow j$.

Se o estado i é comunicável com o estado j e este é comunicável com k , então o estado i é comunicável com k . Ou seja, $i \leftrightarrow j$ e $j \leftrightarrow k$ então $i \leftrightarrow k$.

Diz-se que dois estados pertencem à mesma **classe** se eles são comunicáveis.

É preciso notar que duas classes de estados distintas devem ser disjuntas uma vez que a existência de um elemento comum implicaria que os estados das classes seriam comunicáveis.

Os estados de uma cadeia de Markov consistem de uma ou mais classes (comunicáveis) disjuntas.

Uma cadeia de Markov que consiste de uma única classe é dita ser **irredutível**.




Figura 1: Três classes: $\{0\}$, $\{1, 2\}$ e $\{3\}$.




Figura 2: Uma classe - cadeia irredutível.

Suponha uma cadeia de Markov no estado i . O estado i é dito ser **recorrente** se o processo retorna para o estado com probabilidade 1, ou seja

$$f_i = \Pr[\text{retornar alguma vez para estado } i] = 1 \quad (36)$$

O estado i é dito ser **transiente** se

$$f_i < 1 \quad (37)$$



Recorrência e transiência são *propriedades de classe*:

- ✓ Se o estado i é recorrente (transiente) toda a sua classe é recorrente (transiente);
- ✓ Se uma cadeia de Markov é irreduzível então todos os seus estados ou são transientes ou todos são recorrentes;
- ✓ Os estados de uma cadeia de Markov irreduzível com estados finitos são todos recorrentes.



Outro aspecto que pode ser analisado é que o **diagrama de transição** e as **probabilidades de transição** não nulas podem impor **periodicidade** na cadeia de Markov.

Dizemos que o estado i tem **período** d se ele apenas ocorre em instantes de tempo que são múltiplos de d .

Assim, também dizemos que um estado i é **aperiódico** se ele tem período $d = 1$.



Periodicidade é uma *propriedade de classe*.

- ➡ Todos os estados em uma classe têm o mesmo período;
- ➡ Uma cadeia de Markov irredutível é dita ser aperiódica se os estados na sua classe única tem período 1;
- ➡ Assim, uma cadeia de Markov irredutível é dita ser periódica se seus estados possuem período $d > 1$.




Figura 3: Possíveis estruturas para cadeias de Markov.

Processo de nascimento-e-morte

Um **processo de nascimento-e-morte** é uma cadeia de Markov nas quais as transições entre estados adjacentes ocorrem como representado na Figura 4.




Figura 4: Diagrama de transição de um processo de nascimento-e-morte.

As **equações de equilíbrio** de um processo de nascimento-e-morte geral são dadas por:

$$\lambda_0 p_0 = \mu_1 p_1, \quad j = 0 \quad (38a)$$

$$\lambda_j p_j - \mu_{j+1} p_{j+1} = \lambda_{j-1} p_{j-1} - \mu_j p_j, \quad j = 1, 2, \dots \quad (38b)$$

Com estas equações, para haver equilíbrio devemos ter

$$\lambda_{j-1} p_{j-1} - \mu_j p_j = \text{constante} \quad (39)$$

e pela equação para $j = 0$ temos que

$$\lambda_0 p_0 - \mu_1 p_1 = \text{constante} = 0 \quad (40)$$

Com isso, temos que

$$\lambda_{j-1}p_{j-1} - \mu_j p_j = 0 \quad (41)$$

o que implica em

$$p_j = r_j \cdot p_{j-1}, \quad j = 1, 2, \dots \quad (42)$$

em que $r_j = \left(\frac{\lambda_{j-1}}{\mu_j} \right)$

E usando um argumento de indução simples podemos escrever

$$p_j = r_j r_{j-1} \dots r_1 p_0, \quad j = 1, 2, \dots \quad (43)$$

Se definirmos

$$R_j = r_j r_{j-1} \dots r_1 p_0 \quad \text{e} \quad R_0 = 1, \quad (44)$$

podemos encontrar p_0 como

$$\left(\sum_{j=0}^{\infty} R_j \right) p_0 = 1 \quad (45)$$

Se a série acima converge então a distribuição estacionária é dada por

$$p_j = \frac{R_j}{\sum_{j=0}^{\infty} R_j}. \quad (46)$$